

Relatório do Trabalho Computacional 1

Gabriel Ferreira Lima¹

¹Departamento de ciência da computação - IFCE, campus maracanaú

Abstract. *This document reports the results achieved in Computational Project 1, a project where a Multi-Layer Perceptron was manually developed and tested with a set of hyperparameters on three different datasets: banana, ripley, and two moons.*

Resumo. *Esse documento relata os resultados alcançados no Trabalho Computacional 1, um trabalho onde foi desenvolvido um Multi-Layer Perceptron manualmente e este foi testado com um conjunto de hiperparâmetros em 3 datasets diferentes: banana, ripley e two moons.*

1. Melhor Modelo Utilizado

O melhor modelo varia de dataset para dataset, o dataset banana por sua complexidade demandou uma quantidade maior de neurônios por camada e possivelmente seria ainda melhor se fosse dado a ele mais neurônios. Em todo caso, esse dataset em específico é muito difícil de ser treinado já que ele possui dados de diferentes classes que frequentemente se encontram uns com os outros, erros aqui serão inevitáveis

Os outros datasets demandaram menos neuronios por camada porém mesmo assim um grande número de neurônios e camadas foi benéfico a eles. Em todos os datasets um learning rate extremamente alto foi benéfico, o que sugere um número de épocas muito baixo ou uma possível dificuldade na inicialização de pesos.

2. Hiperparâmetros

Foram testados os seguintes parâmetros:

- Número de neurônios por camada: Variando de 4 a 9
- Número de camadas: Variando de 1 a 4. Esse número se refere à camada de saída somado às camadas escondidas
- Taxa de Aprendizado: Variando entre 0.01, 0.1 e 0.5

Além disso, cada combinação foi testada 10 vezes e calculada a média e o desvio padrão de cada um deles. O resultado final terminou resultando em 216 iterações diferentes e tomou vários minutos para rodar. Uma análise mais robusta demandaria mais tempo

| | dataset | n_neurons | n_layers | learning_rate | accuracy | | recall | | precision | | F1-Score | |
|-----|-----------|-----------|----------|---------------|----------|----------|----------|----------|-----------|----------|----------|----------|
| | | | | | mean | std | mean | std | mean | std | mean | std |
| 0 | df_banana | 4 | 1 | 0.01 | 0.514340 | 0.057448 | 0.188032 | 0.124521 | 0.469491 | 0.212987 | 0.240226 | 0.123495 |
| 1 | df_banana | 4 | 1 | 0.10 | 0.552453 | 0.018235 | 0.120385 | 0.035630 | 0.588019 | 0.175241 | 0.191994 | 0.041805 |
| 2 | df_banana | 4 | 1 | 0.50 | 0.547075 | 0.016379 | 0.126760 | 0.022996 | 0.506572 | 0.072287 | 0.200698 | 0.028769 |
| 3 | df_banana | 4 | 2 | 0.01 | 0.531038 | 0.048772 | 0.131122 | 0.166519 | 0.266221 | 0.249929 | 0.157830 | 0.180837 |
| 4 | df_banana | 4 | 2 | 0.10 | 0.561887 | 0.088187 | 0.278804 | 0.127101 | 0.563155 | 0.189281 | 0.357390 | 0.145453 |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 211 | df_ripley | 9 | 3 | 0.10 | 0.874000 | 0.015578 | 0.863827 | 0.019019 | 0.882518 | 0.030996 | 0.872713 | 0.017797 |
| 212 | df_ripley | 9 | 3 | 0.50 | 0.906800 | 0.014367 | 0.897139 | 0.029492 | 0.917373 | 0.030430 | 0.906587 | 0.017957 |
| 213 | df_ripley | 9 | 4 | 0.01 | 0.526800 | 0.066934 | 0.362307 | 0.363660 | 0.379027 | 0.354983 | 0.338557 | 0.299193 |
| 214 | df_ripley | 9 | 4 | 0.10 | 0.879600 | 0.014416 | 0.873084 | 0.021614 | 0.882130 | 0.020754 | 0.877409 | 0.016724 |
| 215 | df_ripley | 9 | 4 | 0.50 | 0.905600 | 0.019432 | 0.918553 | 0.029512 | 0.888177 | 0.042123 | 0.902207 | 0.021884 |

216 rows x 12 columns

3. Resultados Alcançados

Após todas as iterações serem rodadas, os resultados forem obtidos e o cálculo de média e desvio padrão realizado, filtrei os dados para obter os hiperparâmetros que resultaram no maior F1-Score para cada conjunto de dados.

| | dataset | n_neurons | n_layers | learning_rate | accuracy_mean | accuracy_std | recall_mean | recall_std | precision_mean | precision_std | F1-Score_mean | F1-Score_std |
|-----|-----------|-----------|----------|---------------|---------------|--------------|-------------|------------|----------------|---------------|---------------|--------------|
| 68 | df_banana | 9 | 3 | 0.5 | 0.881321 | 0.007426 | 0.842196 | 0.048369 | 0.894569 | 0.036428 | 0.865807 | 0.013493 |
| 119 | df_moons | 7 | 4 | 0.5 | 0.989500 | 0.007246 | 0.981455 | 0.014043 | 0.986921 | 0.006544 | 0.989133 | 0.008226 |
| 191 | df_ripley | 7 | 4 | 0.5 | 0.911600 | 0.014292 | 0.916626 | 0.041074 | 0.908443 | 0.042695 | 0.910894 | 0.011426 |

4. Discussão dos Resultados:

Como foi possível ver no gráfico, o dataset banana obteve melhor resultado com 9 neurônios por camada e 3 camadas, enquanto os datasets two moons e ripley obtiveram melhor resultado com 7 neurônios por camada e 4 camadas.

Os três datasets se beneficiaram de uma taxa de aprendizado de 0.5, uma taxa curiosamente alta. Entretanto, todos resultaram em valores aceitáveis de acurácia, recall, precisão e F1-Score.

Em conclusão, o maior fator limitante para esse modelo foi a demora ao ajustar pesos, levando a uma necessidade de elevado número de épocas e uma taxa de aprendizado alta para trazer resultados satisfatórios.